PUC-SP

INTELIGÊNCIA ARTIFICIAL

Quatro paradigmas de aprendizagem

Supervisionado, não supervisionado,
semissupervisionado e por reforço

Curso:. Ciência de dados aplicados a IA

Profa: Dra Sandra Bozolan

PUC-SP

Uma tarefa, diferentes formas de aprender

Como ensinar um sistema a organizar uma caixa de entrada?

Com mensagens classificadas por pessoas?

Com mensagens sem categorias?

Com poucas mensagens anotadas?

Com ações e recompensas ao longo do uso?

Uma tarefa, diferentes formas de aprender

Supervisionado

Aprender com mensagens classificadas.



Não supervisionado

Descobrir grupos sem categorias prévias.



Semissupervisionado

Combinar poucos rótulos com muitos exemplos.



Por reforço

Aprender com ações e recompensas.





PUC-SP

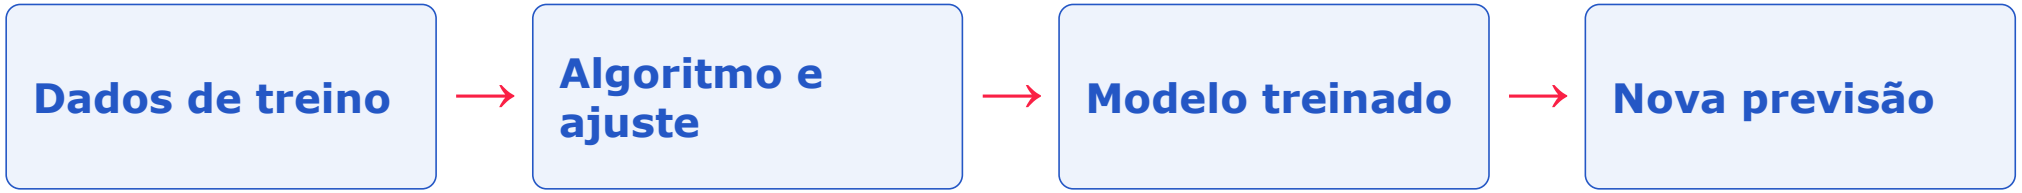
Aprender significa melhorar em uma tarefa

- Tarefa T: reconhecer a espécie de uma flor
- Experiência E: exemplos de flores
- Desempenho P: acertos em flores novas
- A melhoria deve aparecer além dos exemplos já vistos.

PUC-SP

Do algoritmo ao modelo treinado

- Atributos X: medidas disponíveis de cada exemplo
- Rótulo y: resposta conhecida em tarefas supervisionadas
- Algoritmo: procedimento de aprendizagem
- Modelo: resultado do ajuste aos dados
- Inferência: uso do modelo em uma nova entrada



PUC-SP

Quatro origens do sinal de aprendizagem

Paradigma	Sinal	Objetivo típico
Supervisionado	Rótulos conhecidos	Prever classe ou valor
Não supervisionado	Estrutura dos dados	Descobrir grupos
Semissupervisionado	Poucos rótulos + muitos sem rótulo	Prever com menos anotação
Por reforço	Recompensas da interação	Escolher ações em sequência

Como a IA aprende na bolsa de valores

1. Supervisionado

Aprende com respostas conhecidas



Usa dados históricos rotulados para estimar alta ou queda.

2. Não supervisionado

Descobre padrões sem rótulos



Agrupa ações com comportamentos semelhantes.

3. Semissupervisionado

Combina poucos rótulos e muitos dados sem rótulo



Combina poucas notícias classificadas com muitas não classificadas.

4. Por reforço

Aprende com ações e consequências



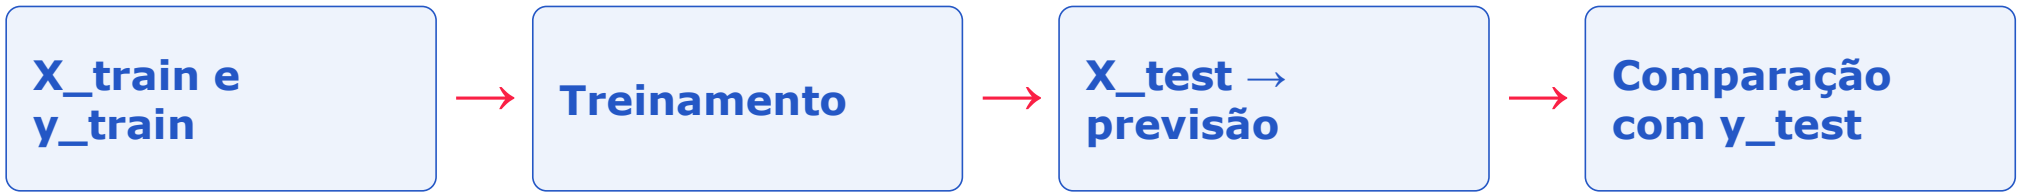
Testa decisões no simulador e recebe recompensas pelo resultado ajustado ao risco.

Exemplo didático com dados fictícios. Previsões não garantem retornos.

PUC-SP

Supervisionado: exemplos com respostas

- Treino: X e y aparecem juntos
- O modelo aprende uma relação entre entrada e saída.
- Teste: novas entradas recebem previsões.
- A avaliação compara previsões com respostas reservadas.



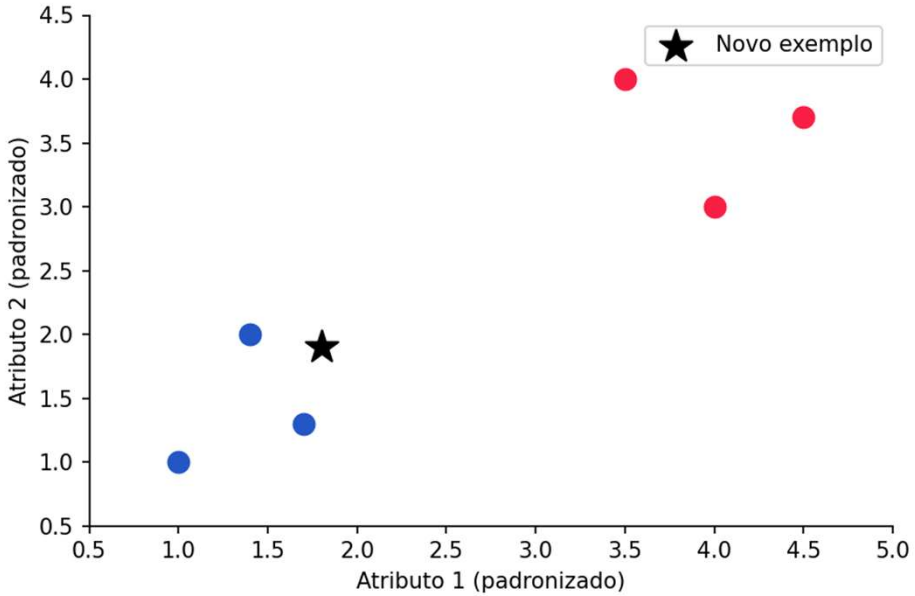
Classificação e regressão

Pergunta	Saída	Tarefa
Esta mensagem é spam?	Spam / legítima	Classificação
Qual é a espécie da flor?	Uma de três espécies	Classificação
Qual será o preço do imóvel?	Valor em reais	Regressão
Qual será o consumo de energia?	Quantidade em kWh	Regressão

PUC-SP

k-NN: a vizinhança orienta a previsão

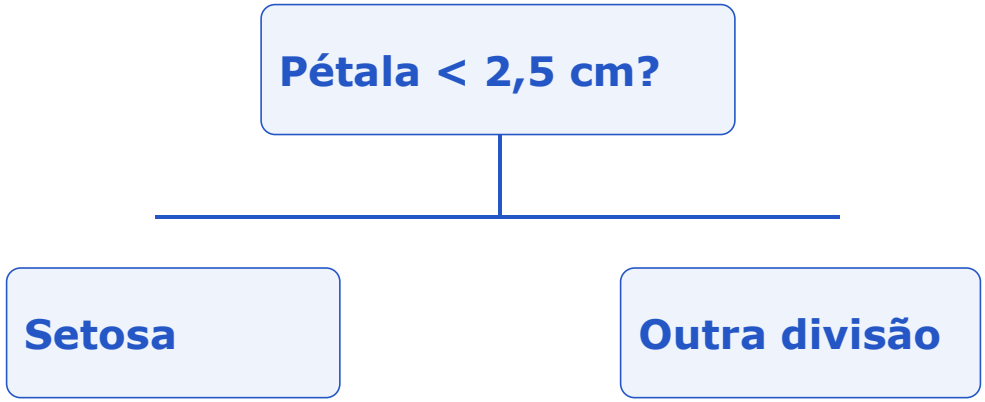
- Uma nova flor procura exemplos próximos.
- k define quantos vizinhos participam.
- Na classificação, a maioria decide.
- A escala dos atributos altera as distâncias.



PUC-SP

Árvores de decisão fazem divisões sucessivas

- Cada nó aplica uma condição a um atributo.
- Cada folha produz uma previsão.
- Profundidade excessiva pode memorizar o treino.
- A árvore facilita a leitura de regras locais.



Regra ilustrativa

PUC-SP

Treino, validação e teste têm papéis diferentes

- Treino: ajusta parâmetros do modelo.
- Validação: orienta escolhas, como k e profundidade.
- Teste: estima o desempenho após essas escolhas.
- Pipeline ajusta a transformação dentro do treino.

Separar os dados → **Ajustar no treino** → **Escolher na validação** → **Avaliar no teste**



PUC-SP

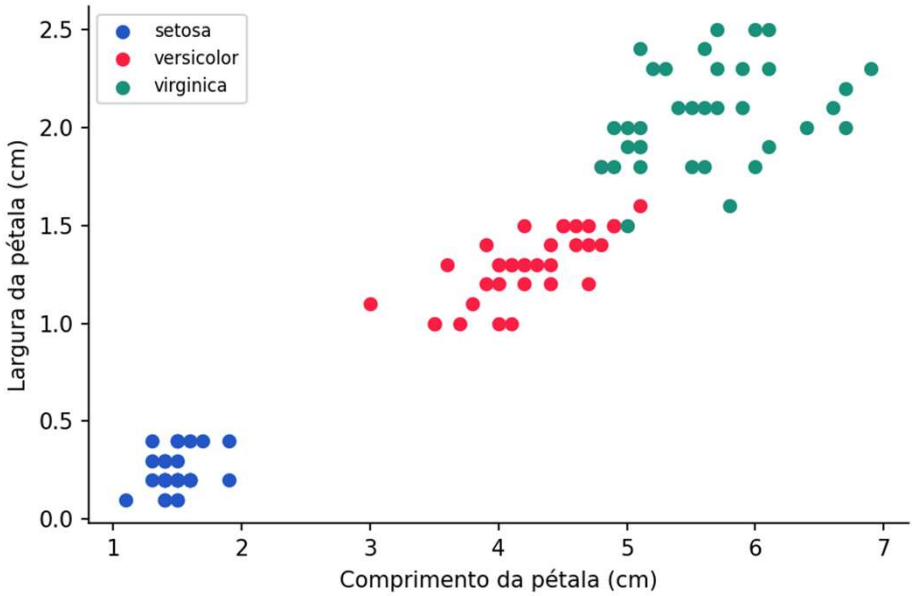
A métrica depende da pergunta

- Acurácia = acertos / total
- Precisão = VP / (VP + FP)
- Revocação = VP / (VP + FN)
- MAE = média dos erros absolutos, para regressão
- Matriz de confusão mostra quais classes se misturam.

PUC-SP

Demonstração 1: classificar flores Iris

- 150 flores, quatro medidas e três espécies
- 105 exemplos para treino e 45 para teste
- k-NN com padronização e k=5
- Árvore com profundidade máxima 3
- O notebook exibe acurácia e matriz de confusão.





PUC-SP

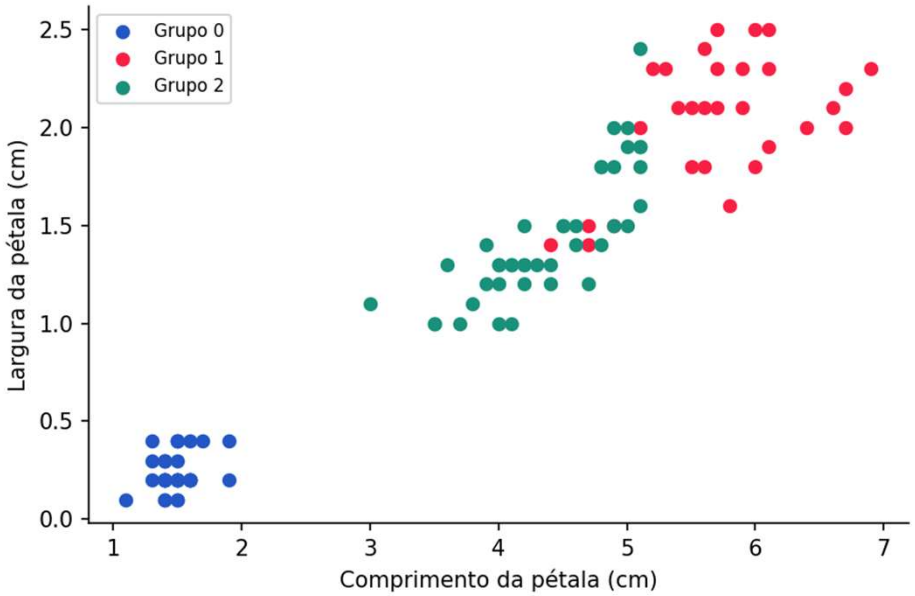
Não supervisionado: descobrir estruturas

- O treinamento recebe atributos sem rótulos-alvo.
- Agrupamento reúne exemplos semelhantes.
- Redução de dimensionalidade cria uma representação menor.
- Segmentação de clientes ajuda a explorar perfis.

PUC-SP

K-means alterna atribuição e atualização

1. Escolher K e inicializar centroides
2. Atribuir cada ponto ao centro mais próximo
3. Atualizar cada centro pela média do grupo
4. Repetir até satisfazer o critério de parada

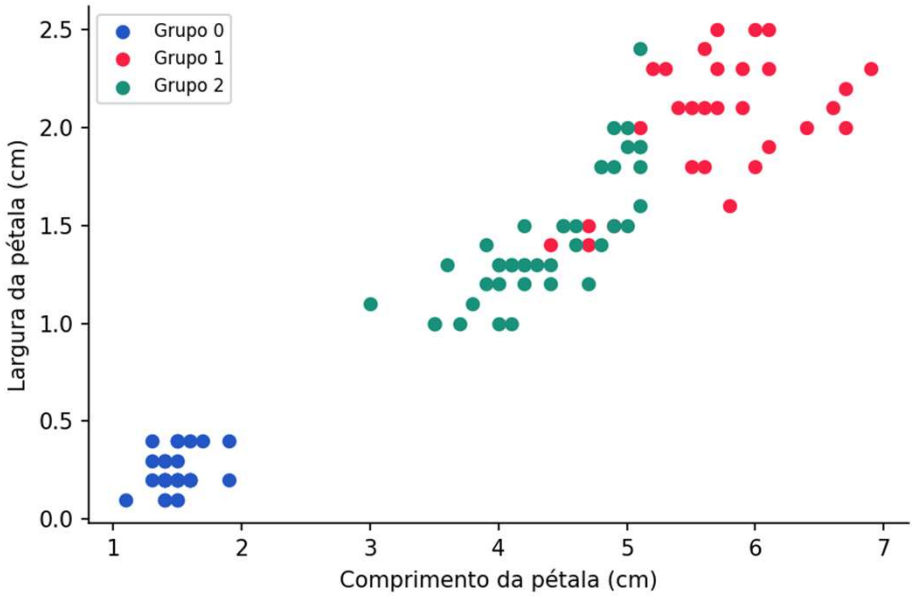


Grupos encontrados precisam de interpretação

- K é uma escolha que afeta a segmentação.
- Padronizar evita domínio de atributos de maior escala.
- Silhueta combina coesão e separação.
- IDs de clusters são identificadores arbitrários.
- Um agrupamento pode atravessar classes reais.

Demonstração 2: Iris sem espécies no ajuste

- Use somente os atributos de treino.
- Ajuste StandardScaler e K-means com K=3.
- Visualize os grupos nas medidas de pétalas.
- Compare K=2 e K=3 pela silhueta.
- Pergunta: os grupos recuperam as três espécies?



PUC-SP

Semissupervisionado: poucos exemplos anotados

- Anotar dados exige tempo e conhecimento.
- O treino combina exemplos com e sem rótulo.
- As regularidades dos dados ajudam a orientar o modelo.
- A hipótese de estrutura pode falhar.



Duas estratégias, dois cuidados

- Pseudo-rotulagem: incorpora previsões selecionadas.
- Self-training repete prever, selecionar e reajustar.
- Label Spreading usa semelhança entre exemplos.
- Erro inicial pode se propagar entre exemplos.
- Confiança alta pode estar mal calibrada.



PUC-SP

Demonstração 3: somente 15 rótulos disponíveis

- Reserve o teste antes de ocultar os rótulos.
- Mantenha cinco flores rotuladas por espécie no treino.
- Baseline: k-NN treinado nessas 15 flores.
- Comparação: Label Spreading com 105 flores
- Avalie os dois métodos nas mesmas 45 flores novas.



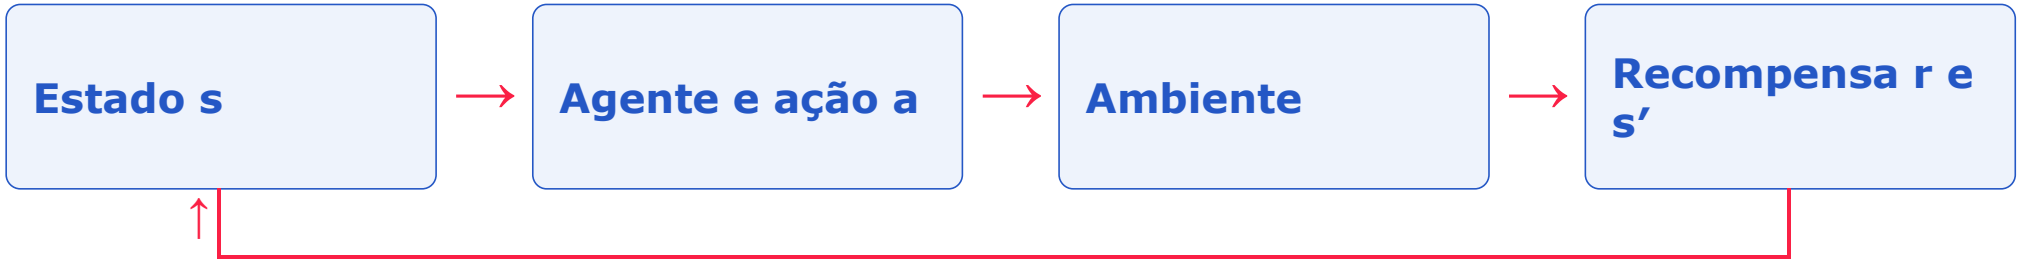
PUC-SP

Semissupervisionado e autossupervisionado

- Semissupervisionado: alguns rótulos externos no treino.
- Autossupervisionado: alvos derivados dos próprios dados.
- Exemplo autossupervisionado: prever uma parte ocultada.
- Indutivo: prever exemplos novos.
- Transdutivo: atribuir rótulos ao conjunto já disponível.

Reforço: aprender pelas consequências

- Agente escolhe ações em um ambiente.
- Estado descreve a situação observada.
- Recompensa avalia uma transição.
- Política orienta a escolha das ações.
- O objetivo considera o retorno acumulado.



PUC-SP

Um robô aprende a chegar ao destino

- Estado: posição na grade 4 × 4
- Ações: cima, baixo, esquerda e direita
- Cada passo: −1; colisão: −5
- Chegada ao destino: +10 e fim do episódio
- Retorno: soma de recompensas com desconto





PUC-SP

Exploração e aproveitamento do que foi aprendido

- Explorar: tentar ações e obter informação.
- Aproveitar: escolher a ação de maior valor estimado.
- Política ε-greedy explora com probabilidade ε.
- Diminuir ε cedo demais pode limitar descobertas.

Q-learning atualiza o valor de uma ação

- $Q(s,a) \leftarrow Q(s,a) + \alpha\,[\text{alvo} - Q(s,a)]$
- $\text{Alvo} = r + \gamma \max Q(s',a')$
- No estado terminal, alvo = r.
- $Q=2;\ \alpha=0{,}5;\ r=-1;\ \gamma=0{,}9;\ \max Q'=4$
- $\text{Novo } Q = 2 + 0{,}5 \times (-1 + 3{,}6 - 2) = 2{,}3$

Recompensa bem definida exige avaliação

- Um objetivo mal definido pode incentivar atalhos.
- Recompensar movimento pode gerar ciclos.
- Teste a política com exploração desativada.
- Observe sucesso, retorno e número de passos.
- Uma simulação não comprova segurança no mundo real.



PUC-SP

Atividade em grupos: escolher e justificar

- A. Prever evasão com histórico rotulado
- B. Descobrir perfis de consumo sem categorias
- C. Classificar documentos com poucos rótulos
- D. Aprender uma sequência de ações no simulador
- Entregar: paradigma, dados, sinal, algoritmo, avaliação e risco.

PUC-SP

Discussão: o que torna uma escolha defensável?

Caso	Paradigma	Avaliação possível
A. Evasão	Supervisionado	Revocação, precisão e análise por grupo
B. Consumo	Não supervisionado	Silhueta, estabilidade e utilidade
C. Documentos	Semissupervisionado	Teste rotulado independente
D. Simulador	Reforço	Sucesso e retorno por episódio



PUC-SP

Avaliação de saída: cinco respostas curtas

1. Prever preço: qual tarefa e paradigma?
2. Agrupar sem rótulos: qual paradigma?
3. Poucos rótulos: qual abordagem pode ajudar?
4. Qual sinal orienta a aprendizagem por reforço?
5. Por que ajustar o scaler apenas no treino?

PUC-SP

A escolha começa pelo sinal disponível

Paradigma	Pergunta de partida	Limitação central
Supervisionado	Tenho respostas confiáveis?	Rótulos e generalização
Não supervisionado	Que estrutura procuro?	Interpretação dos padrões
Semissupervisionado	Posso anotar uma parte?	Propagação de erros
Por reforço	Quais ações e consequências?	Objetivo e exploração